

大科技信贷：一个新的信用风险管理框架*

□黄益平 邱 晗

摘要：大科技信贷是指大科技公司利用大科技生态系统和大数据风控模型这两大工具提供信贷服务，创新信用风险管理框架。这项具有突破性的信贷业务首创于中国，并且已经在很多国家落地，为发展普惠金融服务提供了一个相对稳健的解决方案。本文的目的是分析大科技信贷在中小企业贷款领域的信用风险管理框架的工作机制及其宏观影响。大科技平台及其生态系统通过连接数以亿计的用户实现获客，积累大量的数字足迹，支持实时监测与信用风险评估，同时设计相应的激励机制改善还款管理。本文利用中国某家头部金融科技公司逐笔贷款数据的实证分析表明，与传统风控模型相比，大数据风控模型具有突出的信息优势和模型优势，能够更加准确地预测违约。大科技信贷能够有效降低信用历史较为缺乏借款人的融资门槛，提高金融普惠性，同时因为信贷决策不再依赖资产价格，显著减弱金融加速器机制。

关键词：大科技信贷 普惠金融 中小企业融资 大科技生态系统 大数据风控模型
DOI:10.19744/j.cnki.11-1235/f.2021.0016

一、引言

发展普惠金融是各国政府普遍面临的挑战，其中最艰巨的一个任务是为中小企业特别是小微企业提供融资服务(OECD, 2019)。即便在金融服务业十分发达的英国，也只有大约50%的中小企业能够获得银行贷款^①，在我国，这个比例一度只有20%左右。过去十几年来，我国政府采取了许多措施，努力改善中小企业“融资难”的问题，包括建立大量的小额信贷公司、鼓励商业银行设立普惠金融业务部、定向为中小银行提供流动性支持以及行政性地要求银行提高中小企业贷款在总贷款中的比例等。这些政策取得了一定的成效，但总体看来，“融资难”的局面并没有得到根本性的改变。与此同时，以中小企业为主体的民营企业现在已经在我国的国民经济中占据十分重要的地位，它们对GDP增长、知识产权和城镇就业的贡献已经分别超过了60%、70%和80%。因此，能否有效缓解中小企业“融资难”，不仅事关微观企业的生存，更会影响宏观经济的发展。

中小企业“融资难”的原因很多(Demirgüç-Kunt and Klapper, 2012)，归纳起来主要是两个方面的问题，一是获客难，二是风控难。中小企业大多规模小、数量大、地理位置分散，这样就增加了银行的获客成本。同时，银行通常采用3种方法评估企业信用风险：财务数据、抵押资产和“关系型信贷”，这些方法要成规模地运用到中小企业，难度不小。最传统的方法是分析财务数据，主要看3张表，即资产负债表、利润表和现金流量表，在此基础上判断业务发展状况、预测违约可能性。不过这一方法对数据要求比较高，通常只适用于具有一定规模的成熟企业。对于中小企业贷款，最常见的信用风险管理方法是使用抵押资产。已有的研究发

*本文得到国家社会科学基金重大项目“数字普惠金融的创新、风险与监管研究”(18ZDA091)的资助与支持。作者感谢张春、郭晔、沈艳、黄卓、王靖一、施过儿、李振华、王芳、程志云、林晨、陈舒、赵卫星和马智涛等的帮助与建议。文责自负。邱晗为本文通讯作者。

现,抵押品的使用既可以减少交易前的逆向选择问题(Stiglitz and Weiss, 1981; Cerqueiro et al., 2016),也能够遏制交易后的道德风险问题(Berger et al., 2016)。但实际上绝大部分中小企业也缺乏抵押资产,因此,一些银行就转而采取“关系型信贷”的做法,即利用有关企业及企业主的软信息判断违约的可能性,典型的软信息包括社会地位、人品、企业声誉等(Berger and Udell, 2002; Berger and Udell, 2006; Agarwal and Hauswald, 2010)。浙江台州的3家银行在服务中小企业方面做得不错,实际就是采取“关系型信贷”的做法。这个方法的突破是不依赖财务数据和抵押资产,缺点是规模很难做大,银行要全方位地了解客户,成本很高。孟加拉国的格莱珉银行利用小额信贷帮助贫困农户的生产和生活,意义很大,但却很难实现规模化的服务。

不过近10年来数字金融尤其是大型科技公司信贷(简称大科技信贷, BigTech Lending)的发展,让我们看到了真正解决中小企业特别是小微企业“融资难”问题的曙光。所谓的大科技信贷,主要是指一些大型科技公司利用数字技术提供贷款(Frost et al., 2019)。无论看技术流程、服务规模还是资产质量,大科技信贷很可能是一项具有革命意义的金融创新。而且大科技信贷这一金融业务模式发源于中国,阿里巴巴于2009年组建团队开发阿里小贷业务,并于2010年6月发放第一笔贷款。阿里小贷依托阿里巴巴的电子商务平台,将客户在大科技生态系统里的数据映射为企业和个人的信用评价,向这些通常无法在传统金融渠道获得贷款的弱势群体批量发放“金额小、期限短、随借随还”的小额贷款。阿里小贷形成了一个独特的“3-1-0”信贷模式,即客户花3分钟时间在线上申请贷款;如果获得批准,贷款资金将在1秒种内到达借款人的支付宝账户;整个过程实现0人工干预。从阿里小贷演变过来的网商银行的信贷业务也都延续了这一传统。毫无疑问,大科技信贷模式在形成的过程中也学习、借鉴了许多已有的经验,比如网银的“无接触交易”、“关系型信贷”中的软信息以及个体网络借贷平台的线上信用评估等。

现在大科技信贷的业务模式已经在许多国家落地,但那些大型科技公司开展信贷业务的时间都要比阿里巴巴晚一些,比如,美国的Amazon Lending的业务始于2011年11月,阿根廷的Mercado Libre成立于2017年;印度的Paytim成立于2010年,但其信贷业务的技术框架是之后从蚂蚁金服引进的;韩国社交平台Kakao Talk发起的Kakao银行于2017年获得牌照,腾讯是它的第二大股东^②。其中表现最为突出的还是我国的3家新型互联网银行——微众银行、网商银行和新网银行,它们每年分别可以发放数百万甚至上千万笔的贷款,而且中国大科技信贷的总规模在全球居于首位。更为重要的是,这几家银行的平均不良贷款比率保持在1%~2%左右,这个比率要远远低于传统商业银行中小企业贷款不良率3.2%和规模小于500万元贷款不良率5.5%。

大科技信贷能够取得初步的成功,并且以星火燎原之势很快就在全球蔓延开来,关键在于创造性地形成了一个行之有效的信用风险管理框架,解决了普惠金融最重要的一个痛点,即如何降低小微企业融资管理中信息不对称的程度。大科技信贷能够打破这个僵局,主要是借助数字技术手段,创新信用风险管理,从功能上看,这个框架与传统银行的框架并无本质的差异,但在做法上差别很大。这个新框架的两大支柱是大科技生态系统和大数据风控模型,而大科技生态系统是基于大科技平台建立起来的包括商业、金融、社交、娱乐等活动的综合服务体系。

大科技生态系统的优势在于可以全方位地观察借款人的行为与交易,从客户获取、贷款申请、信用评估、贷款发放直至还款管理,整个过程都在平台上进行,为降低信息不对称的程度提供了可能性。数字金融生态系统相当于替代了传统金融体系中金融机构、市场机制和监管政策所发挥的作用。大科技平台及其生态系统的贡献首先始于“获客”,长尾效应的特征意味着平台在建立起来之后,可以以非常低的边际成本连接数以亿计的用户。其次是“大数据”,用户在生态系统中展开社交、购物、游戏、工作等活动,留下海量的数字足迹,包括小微企业的经营流水、营收趋势与交易网络,折射用户的财务状况、经济活动、社会及网络地位与行为特征,这些数据一方面可以支持风险评估,另一方面还可以让大科技信贷机构实时监测借款人的状况,及时对风险因素做出反应。最后是“还款管理”,如果借款人如期履约还款,有益于其在平台生态系统中的信用与声誉,这样就会进一步鼓励还款。

大数据风控模型主要是替代传统银行利用财务数据和抵押资产管理风险做法。信用风险分析的主要目

的是识别潜在借款人的偿还能力与偿还意愿,如果识别不出来,就会把大量的贷款发给不靠谱的申请人,这就是逆向选择的问题。发出去之后,回收的难度也很大,这就是道德风险的问题。大数据风控模型主要是依靠两个要素,一是大数据,二是机器学习模型。与依赖传统数据与评分卡模型的传统银行风控模型相比,大数据风控模型对违约的预测更加准确,也更稳健(Huang et al., 2020)。而这个风控效率的改进,既有信息优势的成分,也有模型优势的贡献。虽然大数据往往并不包含典型、完整的财务数据,但一般会有小微企业的实时交易数据,能够反映最新的经营状况,而财务报表上的信息往往是显著滞后的,最新数据对于预测未来的业务状况有明显的优势。另外,大数据还包含许多企业与个人的行为信息,相比较而言,行为特征不太容易改变,靠谱的企业主的违约概率通常都比较低。另外,与传统的评分卡模型方法相比,机器学习模型更加擅长于处理数量庞大的数据,而且更能够抓住一些复杂的非线性关系以及解释变量之间的交互作用。

如果说大数据风控模型的作用主要是更准确地预测未来经营状况即偿还能力的变化,同时也更有效地识别出那些靠谱即偿还意愿高的贷款申请人,云计算和人工智能的运用则可以大大提升处理的速度与规模,从而显著降低信贷的运营成本。大科技平台在以极低的边际成本获取海量的客户之外,主要是实时、全方位地监测信贷风险的变化,同时利用平台生态系统尽量降低借款人违约的可能性。这两大支柱相结合构成了大科技信贷新型的信用风险管理框架,使得大规模、低成本、高效率、可持续的小微企业贷款成为可能。图1展示了大科技信贷信用风险管理框架的工作机制。

大科技信贷的应用不仅会提高微观层面的风控效率,也可能产生一系列的宏观影响。最显而易见的就是可以促进金融普惠性。由于缺乏信用积累和抵押,大量中小企业和个人无法在传统金融机构获得贷款。通过移动app等方式,大科技生态系统能够以非常低廉的边际成本触达到这部分“白户”群体,并通过大数据风控模型为他们提供风险定价,降低其融资门槛。已经有多项研究表明,数字金融的普惠效应对促进经济增长有着重要作用(黄益平、黄卓, 2019),例如数字金融将有利于缓解中国东西部发展不平衡的问题(郭峰等, 2020),显著提升农村低收入家庭的收入(张勋等, 2019)、促进创业(谢绚丽等, 2018)和促进落后地区的居民消费(易行健、周利, 2018)。

除了增加信贷广度,大科技信贷的发展还会影响经济金融体系的稳定性。郭品和沈悦(2019)、邱晗等(2018)发现数字金融的发展会影响商业银行的负债结构和风险承担行为,李苍舒和沈艳等(2019)发现网贷行业出险对银行业系统性金融风险、金融不确定性存在溢出效应。本文从企业金融约束的角度出发,发现大科技风控手段可以减弱企业对抵押品的依赖,进而减弱金融加速器机制(Bernanke et al., 1999)。很多银行贷款都是以不动产(主要是房地产)做抵押,在金融加速器机制下,当经济遭受负面冲击时,房价、信贷与经济之间很容易形成恶性循环,这也是许多金融危机的主要形成原因。而小微企业尤其依赖抵押贷款,所以在金融危机中往往小微企业损失最大(OECD, 2019)。以大数据为依据的大科技风控模型,可以为企业尤其是小微企业提供无抵押的信用贷款。减弱了房价与信贷之间的关联,房价下跌不会导致信贷收缩,也就不会导致经济加速下行。从这个角度看,大科技信用贷款有可能增强金融与经济的稳定性。

借助中国某家头部金融科技公司、网商银行和传统银行的数据,本文分析了大科技信贷的信用风险管理框架及其宏观影响,得出以下结论。在现有文献的基础上,本文有以下几点贡献。第一,本文首先提出大科技信贷的信用风险管理框架并详细分析了大科技生态系统和大数据风控模型这两大工具的贡献。第二,本研究确认了大数据风控模型的模型优势和信息优势(Frost et al., 2019;




图1 大科技信贷信用风险管理框架示意图

资料来源:作者整理。

Gambacorta et al., 2019), 并进一步发现除了更高维度的数据, 更广泛的客户群体和更有时效性的信息也有助于提升金融科技风控模型的有效性。第三, 多项研究发现大数据风控模型会对不同群体产生异质性影响 (Fuster et al., 2018; Huang et al., 2020), 本文从传统银行信贷历史的角度出发, 发现数字风控能够改善信用历史较短用户的风险评级, 为大科技信贷促进金融普惠性提供了重要证据。最后, 本文研究了大科技信贷对经济稳定的影响, 通过对比了银行信贷和大科技信贷, 本文发现大科技信贷可以减弱信贷与资产价格的相关性, 促进经济稳定。

本文一共分为五部分, 第一部分为引言, 第二部分介绍大科技生态系统的作用, 第三部分介绍大数据风控模型的作用, 第四部分介绍大科技信贷的宏观影响, 第五部分为结论与政策建议。

二、大科技生态系统

大科技生态系统基于大科技平台建立, 是大科技信贷能够有效运行的重要保证, 通过打造一个集触达用户、贷款申请、信用评价与还款管理于一体的生态闭环, 大科技生态系统能够有效地降低借贷人信息不对称程度, 控制逆向选择和道德风险的问题。过去 10 年来, 国内数字金融领域涌现了诸多五花八门的信贷种类, 比如“P2P”、“现金贷”、“校园贷”等, 到目前为止最为成功的是几家新型互联网银行的信贷, 它们有两个共同的特点, 一是有正规的银行牌照, 也就是说信贷过程要达到合规的要求; 二是以大科技生态系统作为基础设施, 这也是大科技信贷最具特色、最优突破的地方。实际上, 大科技平台及其生态系统也各不相同, 微众银行依托的平台始发于腾讯的社交媒体微信, 而网商银行依托的平台则起源于阿里的网购平台淘宝, 但两家后来都成功地开发了移动支付工具, 并在此基础上建立了一整套的生态系统, 涵盖社交、购物、支付、投资等多方面的日常生活活动。新网银行的模式略有不同, 主要是通过建立一个开放银行的平台, 通过链接其他大科技生态平台比如滴滴打车、美团等提供信贷服务。大科技生态系统的一个共同特点是借款人的大部分活动都在平台上进行, 这为大科技信贷机构降低信息不对称的程度提供了一种新的可能。

具体而言, 大科技生态系统在支持信贷服务方面有 3 个方面的突出优势。第一是极大提升了用户触达性。广泛的客户触达是大科技信贷的基石。不同于传统银行的被动触达(用户提出贷款申请), 大科技公司的触达一般都是借助电商、社交、支付等服务主动触达客户。大科技生态系统链接客户的边际成本很低, 能够覆盖大量之前传统金融无法覆盖的客群, 同时, 主动触达将信用积累做在贷款申请之前, 能够降低用户第一次获得信贷的门槛。最早大科技信贷一般依托其主营业务获得客户, 例如蚂蚁金服起源于服务阿里巴巴平台电商的阿里小贷。而随着移动支付的普及, 大科技公司得以触达到海量的用户, 金融服务渐渐成为一个单独的业务主体。截至 2019 年 6 月, 支付宝及其本地钱包合作伙伴全球用户达到 12 亿^③, 2019 年第四季度微信支付的月活跃用户则是达到 8 亿^④。2017 年, 二维码的普及使得移动支付的生态系统进一步加强。如今, 二维码已经成为了中国小店最常用的支付工具。二维码在消费者和商户之间搭建了桥梁, 帮助科技公司打造了更为全面的生态网络。依靠其生态系统, 大科技风控不止局限于单个用户的分析, 还能引入用户之间的交互信息。Huang 等(2020)发现借款人在生态网络中的重要性可以帮助预测其违约情况。Gambacorta 等(2019)也发现网络重要性越高的用户所能支用的贷款额度就越高。同时, 相比于线下码商, 这种效应对于更加依赖阿里生态体系的线上电商而言更为明显。

第二, 大科技生态系统能够获得丰富实时的用户数据, 为信用风险评估和监控提供基础。借助一体化的移动 app, 大科技公司可以从多个维度获取用户的信息。例如网商银行就能通过线下商户的地理位置、商圈、收入流水、盈利状况、财富管理等信息。而腾讯公司则可以捕捉到用户丰富的社交数据。相比于传统数据, 大科技平台获得的数据有两点优势, 第一是数据维度更加丰富, 可以更精准地对借款人进行评价, 第二是时效性强, 可以让平台实时监测借款人的状况, 及时对风险因素进行反应。

第三, 平台生态可以提高“还款管理”的有效性。基于平台生态的“还款管理”是大科技公司风控的重要手段。“还款管理”一方面通过正向激励提升用户还款意愿, 例如为按时还款的用户提高信贷额度, 提供附加服务

等,另一方面也可以利用生态系统对借款人产生一定的威慑作用。接入央行征信则既有助于减少逆向选择问题,一旦违约,会造成个人与企业的信用污点,遏制道德风险问题。同时,大科技公司可以在预先获得借款人授权的前提下,一旦出现违约,直接通过移动支付工具从用户账户中划走这部分资金,这样就可以进一步降低违约的可能性。

三、大数据风控模型

除了大科技生态系统,大数据风控模型是科技风控能够有效推行的另一重要原因。大数据风控模型为什么比传统风控方式更为有效?本文的初步研究提供了两个方面的解释:一是信息优势,二是模型优势。从信息角度而言,大科技平台获得的数据维度更高,除了传统的风控数据,大科技生态系统还可以获得用户消费、社交等非传统数据,提升模型的预测能力。同时,大科技生态系统触达的样本体量大(尤其是相比于中小银行),获取的信息也更具实效性,有利于科技公司训练风控模型。从模型角度而言,大科技风控引入了更为复杂的模型,这些模型有助于捕捉不同变量之间的交互效应,相比于传统现行模型可以更准确的刻画用户的违约特征。

本文的数据来源于中国一家头部金融科技公司的2017年6月至9月的抽样逐笔贷款数据。该公司的业务逻辑和银行相似,用户在提交贷款申请时该公司会在用户的同意下收集相关风控信息,根据这个信息计算出一个相应的信用分,并依据这个信用分决定是否批准用户的贷款申请。该公司贷款服务对象主要是一些银行信贷并不足以完全满足需求的小微企业主。

本文所利用的变量来源于该公司构造信用分的信息。第一类是传统信息变量(36个),具体包括用户的收入、年龄、性别、不同时间段下银行信用卡信息(违约情况、使用频率、额度、使用历史)。这些传统数据都是银行可以观察到的信息,同时也被广泛运用于银行风控之中。第二类是非传统信息变量(99个),具体包括用户在网络平台上的消费数据,用户的社交数据以及用户的一些其他行为信息。虽然相比传统信息,非传统信息变量数量更多,但数据分布相对离散化。两类不同维度的数据为我们分析大数据风控模型提供了基础。

基于这些数据,我们进一步对比不同模型效果。参考文献中的模型设定(Frost et al., 2019; Gambacorta et al., 2019),本文构建了4个模型。第一个是基于传统信息的逻辑回归模型(模型1),第二个是基于所有信息的逻辑回归模型(模型2),第三个是基于传统信息的随机森林模型(模型3),第四个是基于所有信息的随机森林模型(模型4)。参考Khandani等(2010),本文将随机森林选为机器学习模型的代表。随机森林模型的基本单元是决策树模型,其核心思路就是将样本根据自变量的不同取值范围进行分类,最后给每种不同类别打上标签(在本文中,标签为逾期或者不逾期)^⑤。相比于逻辑回归模型,树模型的优势在于能够捕捉变量之间的交互作用。当然,需要说明的是,机器学习模型的种类很多,大科技公司实际使用的模型可能更为复杂,作为稳定性检验,本文也在《管理世界》网络发行版附录中对比了其他机器学习模型的效果。

本文随机选取数据集中70%的样本作为训练集,剩下30%的样本作为测试集。不同于银行的信贷不良定义,这种小额的互联网信用贷款在违约上有着不一样的特征。以这家公司的数据为例,最大逾期天数只有1天的用户几乎一定会继续履约,而当最大逾期天数到达30天时,继续违约的概率达到了70%。所以在风控时,金融科技公司的逾期定义为用户持续30天没有按时还款。本文采取和该公司一致的定义。

(一)大数据风控模型有效性

在这部分我们对上述4类模型的有效性。本文选取ROC(Receiver Operating Characteristic)曲线下面积(Area under Curve, AUC)作为模型有效性的衡量标准,这一标准被广泛运用在文献当中(Berg et al., 2020)。ROC曲线的纵轴为真正类率(True Positive Rate, TPR),代表预测为正而实际也为正的样本占有所有实际为正样本的比例。ROC曲线的横轴假正类率(False Positive Rate, FPR),代表预测为正实际为负的样本占有所有实际为负样本的比例。ROC曲线上每个点代表不用阈值下模型的判断结果。假定模型能够对样本做出完美预测,则TPR=1, FPR=0。ROC曲线越靠近(1,0)点, AUC越高,模型越有效。

图2画出了4类模型的ROC曲线。模型2(所有数据+逻辑回归)和模型1(传统数据+逻辑回归)的对比以及模型4(所有数据+随机森林)和模型3(传统数据+随机森林)的对比表明引入非传统数据有助于提升模型的有效性。模型3(传统数据+随机森林)和模型1(传统数据+逻辑回归)的对比以及模型4(所有数据+随机森林)和模型2(所有数据+逻辑回归)的对比表明相比于传统的线性模型,随机森林模型有助于提高模型预测能力。表1给出了4类模型的AUC取值以及95%的置信区间。可以看出4类模型存在显著性差异。控制相同的数据,模型2的AUC比模型1的AUC提升了0.0411($=0.6361-0.5950$),模型4的AUC比模型3的AUC提升了0.0527($0.7286-0.6759$);控制相同的数据比较不同的模型,模型3的AUC比模型1的AUC提升了0.0809($0.6759-0.5950$),模型4的AUC比模型2的AUC提升了0.0925($0.7286-0.6361$)。从结果看,引入非传统数据和随机森林模型均可以提升模型的风控能力。因为相比于传统模型,随机森林模型可以挖掘出变量之间的交互作用,达到“1+1>2”的效果。我们也使用不同参数的随机森林模型和其他机器学习方法进行稳定性检验,结果保持稳定^⑥。

表2给出了随机森林模型中重要性排名前十的变量。传统信息(信用卡信息,年龄等)在模型中非常重要,前十名中有7个变量都是传统信用卡信息,这也体现了银行风控的合理性。但是,网络平台消费和与用户社交行为数据在模型中在风控模型中起到了重要的作用。说明引入消费、社交等数据可以提升模型的风控效率,这与王正位等(2020)发现一致。

(二)样本量对风控模型的影响

借助互联网移动设备,大科技平台触达的用户体量极大提升。支付宝、微信等app用户数都超过10亿。可以说,海量的样本是大科技风控的特征之一。图3对比了不同样本量下随机森林模型和传统线性模型的表现。图中的纵坐标是AUC,横坐标是样本量,10%代表使用了训练样本的10%。当样本量不断增加,两个模型的预测能力都会增加,但随机森林模型的增益效果更为明显。这是因为随机森林模型刻画的关系更为复杂,可以做的分类更多,所以样本量的增加对于其预测效果的增加更有帮助。而传统模型主要拟合的是线性关系(虽然逻辑回归是非线性模型,但实际上刻画的还是因变量取对数后的Odds Ratio与自变量的线性关系),当训练样本量到达一定程度时,样本量对模型边际贡献程度就会变低。

(三)信息时效性对风控模型的影响

获取实时信息是大科技平台的另一优势。本文将检验信息实效性对于模型的影响。具体而言,本文用6月的数据(信息)作为模型的训练集,用7月、8月、9月的样本做测试集。这样可以获得相隔3个月(9月),相隔2个月(8月),相隔1个月(7月)3个不同时效性的信息对比。图4展示了预测的结果,纵坐标为模型的AUC,横坐标为预测样本与训练样本间隔的时间,从结果上来看,信息的时效性对传统模型和随机森林模型都有帮助,但对随机森林模型增益更大。原因是时间相邻越近的用户其特征也就更相近,随机森林对于训练样本的挖掘深度要高于传统模型,挖掘出的规律更为复杂,如果使用时效性较高的信息,则可以保证模型从训练样本中挖掘出来的规律尤其是一些复杂规律在预测样本中也适用,随机森林模型预测效果




图2 4类模型的ROC曲线

注:横坐标为假正类率,代表正常贷款中被错误预测为违约贷款的比例。纵坐标为真正类率,代表违约贷款中被准确预测的比例。

表2 随机森林模型下的变量重要性

排序	变量名	重要性分数
1	用户的社交活跃度	0.02747
2	贷款违约的次数	0.02133
3	3个月内信用卡使用的频率	0.02104
4	网络平台消费的额度	0.02058
5	信用卡的坏账率	0.02042
6	Pos机消费次数	0.01926
7	信用卡的利率	0.01905
8	最近一次网络平台的消费时间	0.01881
9	年龄	0.01808
10	信用卡的额度	0.01744

注:重要性分数是根据随机森林中Gini不纯度做的计算。数值越大说明变量越重要。

表1 4类模型的AUC比较

模型类别	AUC	95%置信区间
模型1	0.5950	[0.5891, 0.6009]
模型2	0.6361	[0.6303, 0.6418]
模型3	0.6759	[0.6696, 0.6821]
模型4	0.7286	[0.7231, 0.7340]

注:模型1为基于传统信息的逻辑回归模型,模型2为基于所有信息的逻辑回归模型,模型3为基于传统信息的随机森林模型,模型4为基于所有信息的随机森林模型。

也就更好;但是相应的,如果信息时效性较差,预测样本和训练样本有较大差别,有一些复杂规律并不适用,随机森林模型可能出现过拟合的情况,导致模型外推能力下降。所以更具时效性的信息更有助于随机森林模型提升预测能力,但如果实时信息获取受阻,或者借贷人出现结构性的改变,随机森林模型预测能力可能下降的幅度更大,带来超预期的损失,导致金融风险。

四、大科技信贷的宏观影响

(一)大数据风控模型促进金融普惠

大科技信贷这种新的信用风险框架在推广后可能会带来一系列的宏观影响。其中最为明显的就是提高金融普惠性。通过引入非传统数据,大科技信贷为那些缺少信用历史的用户提供风控服务,降低其信贷的准入门槛。参考 Fuster 等(2018),本文计算了大数据风控模型预测违约率与传统模型预测违约率的差,对比了信用卡历史小于一个季度(3个月)的用户、信用卡历史小于1年的用户和信用卡高于1年的用户,对比结果可见图5。对于信用卡历史小于一个季度的用户,平均而言大数据风控模型给出的评价要高于传统模型(61%的用户获得了更高的评价),而对于信用卡历史大于1年的用户,只有45%的用户获得了更高的评价。这可能是因为信用历史较短的用户,传统财务数据代表性较弱,传统方法往往会给出偏谨慎的评价,而大数据风控模型则结合了大量企业主维度的非传统信息,可以给出更为合理的评价,提高该类别用户的信贷准入概率。

(二)减少信贷对抵押品的依赖,有助于提高经济稳定性

大科技信贷的另一个宏观影响就是降低信贷对抵押品的依赖。抵押品可以有效缓解借贷双方信息不对称的问题,但是可能也会放大经济的波动。在金融加速器模型(Bernanke et al., 1999)机制下,信贷和抵押品价格具有很强的同向性,导致金融市场会加剧实体经济的波动。2008年美国次贷危机的快速蔓延就被认为是这一理论的印证(Mian et al., 2014; Giroud et al., 2017)。具体来看,传统商业银行以抵押作为贷款风控的重要手段。在经济繁荣、资产价格上涨时期,银行会增加放贷供给,造成经济过热;而在经济衰退时,资产价格下跌,商业银行就会减少放贷总额,加剧




图3 不同样本量下大数据风控模型与传统模型比较

注:纵坐标为模型在测试集上的AUC值,横坐标为实际训练集样本占原训练集样本的百分比(例如10%代表使用了10%的原训练集样本训练模型)。




图4 不同信息时效性下大数据风控模型与传统模型比较

注:纵坐标为模型在测试集上的AUC值,横坐标为测试集的月份。




图5 信用卡历史与预测违约率差的累积分布函数

注:横坐标为大数据风控模型预测违约率与传统风控模型预测违约率的差,曲线为其累积分布函数图,图例中,“小于一个季度”表示信用卡历史小于一个季度(3个月)的用户;“一个季度到一年”表示信用卡历史一个季度到一年之间的用户;“一年以上”表示信用卡历史高于1年的用户。

经济的萧条。商业银行信贷的这种顺周期特性,增加了实体经济的波动。

金融加速器机制在小微企业融资中尤为明显。由于小微企业的信息不对称程度更高,所以贷款更依赖于抵押品(图6),这就导致在资产价格波动时小微企业信贷受到的影响更大。已有研究发现抵押品渠道是金融危机传导到实体经济尤其是小微企业经营的重要渠道(Adelino et al., 2015)。考虑到抵押贷款的这些劣势,我国政府也在积极推动提高信用贷款的比例。2019年4月17日国务院常务会议就提出“要引导银行提高信用贷款比重,降低对抵押担保的过度依赖”^⑦,但是对于传统银行而言,由于信息不对称问题严重,为小微企业提供信用贷款可能会面临成本过高或是风险过大的两难问题,推广存在一定难度。所以不仅在中国,其他国家甚至是发达国家的小微企业贷款大部分还是需要依赖抵押品。

近年来,以网商银行网商贷为代表的网络信用贷款获得快速发展,与传统银行抵押贷款模式不同,这些信用贷款以大数据风控作为贷款风险定价基础,可以让借贷企业(尤其是小微企业)减少对抵押品的依赖。一方面帮助缺少抵押品的小微企业获得贷款,体现其普惠性;另一方面也减弱小微企业信贷随资产价格的波动性,对经济稳定有着积极的作用。

为了论证上述观点,本文获取了2005~2013年传统银行小微企业(调查网点层面)、2011~2017年网商银行小微企业信用贷款金额数据(地级市层面)、城市房价、人均GDP、常住人口、银行网点覆盖率(每平方公里银行网点数)。传统银行数据来源于北京大学县域金融机构调查(边文龙等,2017),网商银行数据由蚂蚁研究院提供。本文构造的回归方程如下:其中 $y_{i,t}$ 是总信贷额(取对数), $\ln hp_{i,t}$ 是房价(取对数), $Z_{i,t}$ 是控制变量,包括人均GDP(取对数)、银行网点覆盖率、常住人口数(取对数), δ_i 是城市的固定效应, η_t 是年份的固定效应。

$$y_{i,t} = \alpha + \beta \times \ln hp_{i,t} + \gamma \times Z_{i,t} + \delta_i + \eta_t + \varepsilon_{i,t} \quad (1)$$

表3展示了回归的结果,从结果可以看出,传统银行总贷款和房价呈现正相关关系,具体而言,房地产价格每增加10%,总贷款增加3.7%。我们将总贷款拆分为信用贷款和抵押贷款,可以发现房地产价格主要作用于抵押贷款(房地产价格每增加10%,抵押贷款增加9.08%),而对银行信用贷款则没有影响。进一步的,我们对比了网商银行和传统银行对小微企业的贷款。可以发现由于传统银行对小微企业的贷款多依赖于抵押品,两者存在显著的相关关系,且相关性高于总贷款。具体而言,房地产价格每增加10%,小微企业贷款增加4.9%。但是网商银行小微贷款却不受房地产价格的影响。说明相比于传统银行贷款,基于平台生态和大数据模型的科技贷款与资产价格的共振并不强烈,能够提升经济体系的稳定性。需要说明的是,由于数据所限,本文使用的银行贷款为2005~2013年,网商银行贷款为2011~2017年,时期并不一致,结论可能并不具有一般性。但传统信贷与抵押品价格之间存在正相关的关系在其他国家也成立(Liu et al., 2013),而且本文已经控制了时间固定效应来避免国家宏观层面的影响,在一定程度上缓解了时期不一致的问题。当然,本文只是从抵押品这一个视角来探究大科技信贷对金融加速器机的影响。大科技信贷所参考的经营流水等数据是否会带来新的加速器机制还有待研究。大科技信贷可能减弱了“金融加速器”的作用,也可能同时增强“其他加速器”的作用。




图6 各国小微企业抵押贷款占比(2015)

数据来源:Financing SMEs and Entrepreneurs: An OECD Scoreboard。

表3 资产价格与银行信贷供给

贷款额度(log)	传统银行				网商银行
	总贷款	信用贷款	抵押贷款	小微企业贷款	小微企业贷款
房地产价格(log)	0.373* (0.207)	-0.0694 (0.428)	0.908** (0.432)	0.491** (0.192)	0.218 (0.451)
控制变量	是	是	是	是	是
年度固定效应	是	是	是	是	是
城市固定效应	是	是	是	是	是
R	0.229	0.169	0.253	0.033	0.702
观测值	3086	2207	2176	2385	1469

注:因变量为总信贷额度(取对数),自变量为房地产价格(取对数),控制变量为人均GDP(取对数),银行网点覆盖率(网点数/城市面积),常住人口数(取对数),回归控制了城市固定效应和年份固定效应,***p<0.01;**p<0.05;*p<0.1。

五、结论及启示

创始于中国的大科技信贷为普惠金融发展提供了一个革命性的解决方案。目前一些大科技公司已经可以快速、高效地为缺乏财务数据和抵押资产的普惠金融客户提供商业可持续的信贷支持,有的一年已经能够发放超过1000万笔的贷款,同时保持较低的不良贷款比例。最近几年支付宝和微信支付通过推广二维码支付,将上亿的线下个体经营户纳入支付与信贷服务网络,这样就进一步扩大了大科技信贷服务的对象。在2020年上半年的新冠肺炎疫情期间,大科技信贷更是充分发挥无接触交易的优势,成为宏观经济的稳定力量。网商银行与传统商业银行合作,在短短的几个月内,联合发放超过1000万笔的贷款。如果这个信贷模式能够得到稳健的发展、推广,那么,绝大多数中小微企业和低收入人群都有可能获得市场化、商业可持续的融资服务,这在人类经济史上将是第一次。

大科技信贷的革命性突破,主要是基于其新的信用风险管理框架,这个框架依靠两大数字技术工具,一是大科技生态系统,二是大数据风控模型。大科技生态系统的突出优点是可以覆盖从获客、贷款申请、风险评估、监测到还款管理整个流程中的绝大部分活动,这就为降低信息不对称、控制逆向选择和道德风险问题提供了有效途径与手段。大科技生态系统中留下的海量的数字足迹,聚集起来构成了大数据,这些大数据一方面可以用于实时监测,有助于平台快速地调整业务策略,另一方面则可以支持大数据风控模型,本文的实证研究表明,这类新型的风控模型不仅可以更加准确地预测违约率,更重要的是可以为许多缺少银行信用历史的借款人提供融资服务,充分地体现了大科技信贷的普惠性特点。同时,由于大科技信贷不依赖抵押资产,弱化了资产价格与信贷之间的顺周期机制,有利于提高金融与经济的稳定性。

大科技信贷于2010年问世,首先是一个“中国故事”,但这个创新是有世界意义的。大科技信贷的信用风险管理框架包含许多前所未有的做法,虽然它沿袭了“关系型信贷”的思维方式,比如看人品,但它把原先线下一对一频繁接触的做法变成了线上无接触、大规模的运算。平台和模型加在一起,多方位地突破了普惠金融发展的障碍:(1)大规模、低成本地获客;(2)许多缺乏传统信贷资质客户的准入;(3)全程、实时的监测;以及(4)对还款能力与还款意愿的较好预测与管理。更重要的是,现在这个模式已经走向世界。

但大科技信贷还仅仅只是走出了第一步,这个普惠金融业务模式的成熟和普及还需要数字金融机构与监管部门的共同努力。第一,大科技信贷的风控方法解释性较低,类似于“黑箱子”,监管部门并不能很好地识别这类贷款的稳定性。不少官员虽然承认大科技信贷在风控方面的有效性,但他们也认为这个业务模式尚未经过完整的金融周期的检验。之前已经有研究分析表明,在遭受政策冲击之后,与传统银行风控模型相比,大数据风控模型的相对优势变得更为突出,这可能是因为大数据既包含实时变量,又有行为数据,因此对冲击后的预测也就更为可靠(Huang et al., 2020)。但在金融周期转向之后,大数据风控模型的优势还能不能保持,确实还需要耐心地观察、分析实际的变化。第二,如果企业或个人明白大科技平台及其生态系统根据他们留下的数字足迹作为信用风险管理框架的基础,他们的线上“足迹”可能会因此改变,从而带来欺诈风险。第三,大科技利用用户的社交、购物、网页浏览和金融账户等数据进行建模,客观上提高了风控能力,但也可能带来数据隐私和“算法歧视”等问题。第四,基于数据的贷款虽然提高了金融的普惠程度,但也可能加大一些特殊群体(例如中老年群体)与社会的差距,导致“数字鸿沟”的产生。总的来说,大科技信贷促进了金融的普惠性,但同时带来了一些问题和挑战,需要进一步的研究完善。

政府及监管部门可以采取如下措施,支持大科技信贷的健康发展。第一,完善监管制度,加强顶层设计。政府应建立权责分明的监管体系,加强监管协调,完善相关技术和业务标准,促进金融科技行业有序合规发展。第二,加强数据隐私保护,制定相关数据行业标准,推动数据要素市场健康发展。监管部门应进一步完善数据采集、管理和使用的监管规则,同时也需要制定金融科技行业的数据标准,在合规条件下推动传统金融机构和科技公司的数据合作,提高我国金融效率。第三,严格市场准入,推行功能监管。一方面,监管部门应坚持金融行业持牌经营,采用穿透式的功能监管,保证金融业务监管全覆盖,同时发展监管科技,提升风险识别

能力;另一方面也要在合规的基础上保证市场准入的开放,促进科技信贷市场的公平竞争,保护小微企业及低收入个人借款者的利益。第四,完善数字基础设施建设,释放“数字经济”红利。根据本文的研究,大科技信贷有效的原因之一就是在风控中引入了多维度、高时效性的信息。政府可以通过完善数字基础设施,融合多方数据,扩大数字技术服务范围,进一步提升大科技信贷的覆盖广度与风控效率,帮助中老年人等特殊群体跨越“数字鸿沟”。第五,为科技信贷发展提供公平的市场环境。一方面,监管部门应将新兴金融业务纳入统一的监管框架,避免监管套利。但另一方面也应在风险可控的基础上放开一些行业限制,为科技信贷市场提供公平的竞争环境。例如目前新型互联网银行无法实现“远程开户”,这客观上导致了其缺乏稳定的存款资金,在一定程度上提高了它们的资金成本及不稳定性。可以考虑在尝试开放互联网“远程开户”限制,降低其融资成本,从而增加互联网贷款市场的竞争,促进数字普惠贷款的发展。

(作者单位:北京大学国家发展研究院、北京大学数字金融研究中心)

注释

①英格兰央行副行长 Dave Ramsden 爵士 2019 年 10 月 27 日在上海会面时提供给作者的数据。

②美国 Lending Club 成立于 2006 年,2007 年开始作为个体借贷平台运作,因此从时间上来说早于阿里小贷。但 Lending Club 本身并不是一家大型科技公司,而且作为一个 P2P 平台,虽然它也做信用评估,但贷款决策是由投资者自己做的,Lending Club 只是作为一个服务平台收取手续费。因此,我们并未将其纳入大科技信贷的类别。

③<https://www.ithome.com/0/446/945.htm>。

④<http://www.weishangagent.com/newsInfo/285088.html>。

⑤关于随机森林的详细建模介绍可参见《管理世界》网络发行版附录一。

⑥由于篇幅所限,稳健性检验结果可以见《管理世界》网络发行版附录二。

⑦http://www.gov.cn/zhengce/2019-04/29/content_5387270.htm。

参考文献

- (1)边文龙、沈艳、沈明高:《银行业竞争度,政策激励与中小企业贷款——来自 14 省 90 县金融机构的证据》,《金融研究》,2017 年第 1 期。
- (2)郭峰、王靖一、王芳、孔涛、张勋、程志云:《测度中国数字普惠金融发展:指数编制与空间特征》,《经济学(季刊)》,2020 年第 3 期。
- (3)郭品、沈悦:《互联网金融、存款竞争与银行风险承担》,《金融研究》,2019 年第 8 期。
- (4)李苍舒、沈艳:《数字经济时代下新金融业态风险的识别、测度及防控》,《管理世界》,2019 年第 12 期。
- (5)黄益平、黄卓:《中国的数字金融发展:现在与未来》,《经济学(季刊)》,2018 年第 4 期。
- (6)邱晗、黄益平、纪洋:《金融科技对传统银行行为的影响:基于互联网理财的视角》,《金融研究》,2018 年第 11 期。
- (7)王正位、周从意、廖理、张伟强:《消费行为在个人信用风险识别中的信息含量研究》,《经济研究》,2020 年第 1 期。
- (8)谢绚丽、沈艳、张皓星、郭峰:《数字金融能促进创业吗?——来自中国的证据》,《经济学(季刊)》,2018 年第 4 期。
- (9)易行健、周利:《数字普惠金融发展是否显著影响了居民消费——来自中国家庭的微观证据》,《金融研究》,2018 年第 11 期。
- (10)张勋、万广华、张佳佳、何宗樾:《数字经济、普惠金融与包容性增长》,《经济研究》,2019 年第 8 期。
- (11)Adelino, M., Schoar, A. and Severino, F., 2015, “House Prices, Collateral and Self-employment”, *Journal of Financial Economics*, Vol.117(2), p.288~306.
- (12)Agarwal, S. and Hauswald, R., 2010, “Distance and Private Information in Lending”, *The Review of Financial Studies*, Vol.23(7), pp.2757~2788.
- (13)Berg, T., Burg, V., Gombović, A. and Puri, M., 2020, “On the Rise of Fintechs: Credit Scoring Using Digital Footprints”, *The Review of Financial Studies*, Vol.33(7), pp.2845~2897.
- (14)Berger, A. N., Frame, W. S. and Ioannidou, V., 2016, “Reexamining the Empirical Relation between Loan Risk and Collateral: The Roles of Collateral Liquidity and Types”, *Journal of Financial Intermediation*, Vol.26, pp.28~46.
- (15)Berger, A. N. and Udell, G. F., 2002, “Small Business Credit Availability and Relationship Lending: The Importance of Bank Organizational Structure”, *The Economic Journal*, Vol.112(477), pp.32~53.
- (16)Berger, A. N. and Udell, G. F., 2006, “A More Complete Conceptual Framework for SME Finance”, *Journal of Banking & Finance*, Vol.30(11), pp.2945~2966.
- (17)Bernanke, B. S., Gertler, M. and Gilchrist, S., 1999, “The Financial Accelerator in a Quantitative Business Cycle Framework”, *Handbook of Macroeconomics* 1, pp.1341~1393.
- (18)Cerqueiro, G., Ongena, S. and Roszbach, K., 2016, “Collateralization, Bank Loan Rates and Monitoring”, *The Journal of Finance*, Vol.71(3), pp.1295~1322.
- (19)Demirgüç-Kunt, A. and Klapper, L., 2012, *Measuring Financial Inclusion: The Global Findex Database*, The World Bank.
- (20)Frost, J., Gambacorta, L., Huang, Y., Shin, H. S. and Zbinden, P., 2019, “BigTech and the Changing Structure of Financial Intermediation”, *Economic Policy*, Vol.34, pp.761~779.

(下转第 50 页)

- (31) Peress, J., 2014, "The Media and the Diffusion of Information in Financial Markets: Evidence from Newspaper Strikes", *The Journal of Finance*, 69(5), pp.2007~2043.
- (32) Pesaran, M. H. and Smith, R., 1995, "Estimating Long-run Relationships from Dynamic Heterogeneous Panels", *Journal of Econometrics*, 68(1), pp.79~113.
- (33) Pesaran, M. H., 2006, "Estimation and Inference in Large Heterogeneous Panels with Multifactor Error Structure", *Econometrica*, 74, pp.967~1102.
- (34) Pesaran, M. H., 2015, "Testing Weak Cross-sectional Dependence in Large Panels", *Econometric Reviews*, 34(6), pp.1089~1117.
- (35) Pope, D. G. and Sydnor, J. R., 2011, "What's in a Picture? Evidence of Discrimination from Prosper. Com", *Journal of Human Resources*, 46(1), pp.53~92.
- (36) Smales, L. A., 2014, "News Sentiment in the Gold Futures Market", *Journal of Banking and Finance*, 49, pp.275~286.
- (37) Tang, H., 2019, "Peer-to-peer Lenders Versus Banks: Substitutes or Complements?", *The Review of Financial Studies*, 32(5), pp.1900~1938.
- (38) Teh, Y. W., Jordan, M. I., Beal, M. J. and Blei, D. M., 2006, "Hierarchical Dirichlet Processes", *Journal of the American Statistical Association*, 101(476), pp.1566~1581.
- (39) Tetlock, P. C., Saar-Tsechansky, M. and Macskassy, S., 2008, "More than Words: Quantifying Language to Measure Firms' Fundamentals", *The Journal of Finance*, 63(3), pp.1437~1467.
- (40) Tetlock, P. C., 2007, "Giving Content to Investor Sentiment: The role of Media in the Stock Market", *The Journal of Finance*, 62(3), pp.1139~1168.
- (41) Turner, J. D., Ye, Q. and Walker, C. C., 2018, "Media Coverage and Stock Returns on the London Stock Exchange 1825~70", *Review of Finance*, 22(4), pp.1605~1629.
- (42) Vallee, B. and Zeng, Y., 2019, "Marketplace Lending: A New Banking Paradigm?", *The Review of Financial Studies*, 32(5), pp.1939~1982.
- (43) Wardrop, R., Zhang, B., Rau, R. and Gary, M., 2015, *Moving Mainstream: The European Alternative Finance Benchmarking Report*, Cambridge: University of Cambridge.
- (44) Zhang, J., Härdle, W. K., Chen, C. Y. and Bommers, E., 2016, "Distillation of News Flow Into Analysis of Stock Reactions", *Journal of Business and Economic Statistics*, 34(4), pp.547~563.
- (45) Zhang, L. M. and Chen, S., 2019, "China's Digital Economy, Opportunities and Risks", IMF Working Paper, 19/16.
- (46) Zheng, K., Kelly, B. and Xiu, D., 2019, "Predicting Returns with Text Data", NBER Working Paper, 26186.
- (47) Zou, L., Cao, K. D. and Wang, Y., 2019, "Media Coverage and the Cross-Section of Stock Returns: The Chinese Evidence", *International Review of Finance*, pp.707~729.
- (48) 黄益平:《互联网金融解决了普惠金融的痛点》,《企业观察家》,2016年第5期。
- (49) 李苍舒、沈艳:《风险传染的信息识别——基于网络借贷市场的实证》,《金融研究》,2018年第11期。
- (50) 沈艳、陈赞、黄卓:《文本大数据分析在经济学和金融学中的应用:一个文献综述》,《经济学(季刊)》,2019年第7期。
- (51) 汪昌云、武佳薇:《媒体语气、投资者情绪与IPO定价》,《金融研究》,2015年第9期。
- (52) 王靖一、黄益平:《金融科技新闻文本情绪的刻画与对网贷市场的影响》,《经济学(季刊)》,2018年第7期。
- (53) 谢平、邹传伟、刘海二:《互联网金融模式研究》,《金融研究》,2012年第11期。
- (54) 游家兴、吴静:《沉默的螺旋:新闻文本情绪与资产误定价》,《经济研究》,2012年第7期。
- (55) 张晓朴:《互联网金融监管的原则:探索新金融监管范式》,《金融监管研究》,2014年第2期。

=====

(上接第21页)

- (21) Fuster, A., Goldsmith-Pinkham, P., Ramadorai, T. and Walther, A., 2018, "Predictably Unequal? the Effects of Machine Learning on Credit Markets", CEPR Working Paper, DP12448.
- (22) Gambacorta, L., Huang, Y., Qiu, H. and Wang, J., 2019, "How do Machine Learning and Non-traditional Data Affect Credit Scoring? New Evidence from a Chinese Fintech Firm", BIS Working Papers, No.834.
- (23) Giroud, X. and Mueller, H. M., 2017, "Firm Leverage, Consumer Demand and Employment Losses during the Great Recession", *The Quarterly Journal of Economics*, Vol.132(1), pp.271~316.
- (24) Huang, Y., Zhang, L., Li, Z., Qiu, H., Sun, T. and Wang, X., 2020, "Fintech Credit Risk Assessment for SMEs: The Case in China", IMF Working Paper 20/193.
- (25) Khandani, A. E., Kim, A. J. and Lo, A. W., 2010, "Consumer Credit-risk Models via Machine-learning Algorithms", *Journal of Banking & Finance*, Vol.34(11), pp.2767~2787.
- (26) Liu, Z., Wang, P. and Zha, T., 2013, "Land-price Dynamics and Macroeconomic Fluctuations", *Econometrica*, Vol.81(3), pp.1147~1184.
- (27) Mian, A. and Sufi, A., 2014, "What Explains the 2007~2009 Drop in Employment?", *Econometrica*, Vol.82(6), pp.2197~2223.
- (28) OECD, 2019, "Financing SMEs and Entrepreneurs 2019: An OECD Scoreboard", OECD Publishing.
- (29) Stiglitz, J. E. and Weiss, A., 1981, "Credit Rationing in Markets with Imperfect Information", *The American Economic Review*, Vol.71(3), pp.393~410.

Big Tech Lending: A New Credit Risk Management Framework

Huang Yiping^{a,b}, Qiu Han^{a,b}

(a. National School of Development, Peking University; b. Institute of Digital Finance, Peking University)

Summary: SME financing is a common challenge faced by all countries. Main obstacles boil down to customer acquisition and risk management. Generally speaking, mainstream risk management channels employed by traditional banks include analyzing financial statement holding collateral assets and applying relationship banking. However, it's unrealistic to apply these methods on SMEs at large scale, as most SMEs lack financial data and collateral assets. Therefore, some banks turn to develop relationship banking, i.e., using soft information of enterprises and business owners to forecast default probability. Such method is independent of accounting data and collateral assets, but is still difficult to scale up due to costly demand of client information.

During the last decade, the development of fintech, especially big technology company credit (Big Tech credit), provides a possible solution for SME financing. Big Tech credit refers to credit supply supported by digital techniques of large technology companies. Originated in China, Big Tech credit is a revolutionary financial innovation. Initial success of BigTech credit can be attributed to the creative and effective credit risk management framework. The backbone of this new framework is the big-data risk assessment model and the BigTech platform and its ecosystem, a comprehensive service system based on BigTech platforms, accommodating business, finance, social, entertainment and many other activities.

The advantage of the BigTech platform ecosystem is that it can observe the behavior and transactions of borrowers in an all-round way, which is equivalent to the role played by financial institutions, market mechanisms and regulatory policies in the traditional financial system. The contribution of large technology platforms and their ecosystems first begins with "customer acquisition". The characteristic of the long tail effect enables the platform to connect hundreds of millions of users at a very low marginal cost. The second is "big data". Users leave massive digital footprint, reflecting users' financial status, economic activities, social status and behavioral characteristics. Besides risk assessment, it allows BigTech company to monitor client status in real time and to respond to risk factors in a timely manner. Last but not least, there is "repayment management". Complying with repayment schedules benefits credit and reputation in the platform ecosystem, which further encourages repayment on time.

Fintech risk assessment approach identifies default risk without accounting data and collateral assets used by traditional banks. The fintech risk assessment approach mainly features two advantages: data advantage and model advantage. From the data perspective, it usually provides real-time transaction information of SMEs that reflects latest business conditions. In addition, big data also contains behavioral information. From the model side, machine learning models are better at capturing complex nonlinearity and interactions among variables compared with traditional methods.

We analyze the risk management framework of BigTech credit and its implication for macroeconomy. Building on existing literature, this paper arrives at the following conclusions. First, this article pioneers in proposing a credit risk management framework for big tech credit and analyzes in detail the contributions of the BigTech platform ecosystem and fintech risk assessment approach. Second, this paper confirms model and information advantages of the fintech risk assessment approach. It further reveals that in addition to higher-dimension data, larger customer group and more time-sensitive information also help to improve the fintech risk assessment approach. Third, this paper finds that digital risk control facilitates risk rating of users with shorter credit history. Fourth, this paper finds that Big Tech credit weakens the correlation between credit and asset prices and promotes financial stability.

Keywords: big tech lending; financial inclusion; SMEs financing; big tech platform; fintech risk assessment approach

JEL Classification: G20, G30

附录一 随机森林

随机森林是一种有监督学习方法。顾名思义,其运算原理就是先构建众多决策树模型,再通过投票等方式得出一个综合结果。一个典型的二分类决策树模型由根节点、内部节点、叶节点和边组成。根节点和内部节点代表一个自变量,模型会根据自变量不同的取值(边)进行判断,进入下一个内部节点或者叶节点。而叶节点则是树的末梢,代表模型对因变量的判断结果。

如何构建一个决策树?其关键就是找到一个分类的标准,即选取合适的分类变量和相应的分类方法。在本文中,我们选取基尼不纯度来衡量分类标准好坏的指标,不纯度越低,说明分类可以给出越清楚的识别,即分类越有效。对于节点 m (对应样本 D_m ,样本个数为 N_m),我们定义基尼不纯度为:

$$Gini(D_m) = 2p_m(1-p_m)$$

其中, p_m 是区域 D_m 中违约的概率。如果样本 D_m 中只有违约的样本或者没有违约的样本,则 $Gini(D_m)$ 等于0。

现在我们给出一个对节点 m 分类的标准。假定我们选取 A 作为分类变量,根据某个分类方法可以把样本 D_m 分为两个子样本, $D_{m,1}$ 和 $D_{m,2}$,定义在上述分类标准下的基尼不纯度为:

$$Gini_A(D_m) = \frac{N_{m,1}}{N_m} Gini(D_{m,1}) + \frac{N_{m,2}}{N_m} Gini(D_{m,2})$$

根据这个分类标准(A 变量及相应的分类方法),基尼不纯度的降低幅度为:

$$\Delta Gini(A) = Gini(D_m) - Gini_A(D_m)$$

可以使得基尼不纯度降低幅度最大的变量以及相应的分类方法,即被选为最优的分类标准。

根据基尼不纯度的标准,我们可以开始构造决策树模型。

1. 给定一个节点 m ,对应着样本 D_m ,如果样本中只有一个类别(违约或者不违约),则将节点 m 变为叶节点,其判断结果为样本的类别。如果没有变量能够作为分类变量,则将节点 m 变为叶节点,使用样本 D_m 中最多的类别作为判断结果。
2. 如果节点 m 没有1中所说的情况,则可以根据基尼不纯度的标准对节点 m 进行分类,并产生新的节点。
3. 循环1和2的过程,直到产生的所有节点都为叶节点或者树的深度达到外生给定的最大值。

根据不同的子样本和变量,我们可以得到多棵决策树。对于某一个用户,每一棵决策树都会给出一个判断结果(违约或者不违约),我们选取数量最多的结果作为整个随机森林模型的判断结果。根据变量对基尼不纯度的降低程度,我们也可以计算出不同变量在模型中的重要性。

附录二 稳健性检验

为了避免随机森林模型在这个数据集的特殊性,我们也使用其他两个机器学习方法进行稳健性检验。第一个方法是梯度下降树(GBDT, Gradient Boosting Decision Tree),第二个方法是Adaboost。同时,机器学习模型可以通过调整参数提高拟合效果。为了避免是某个参数导致了文章中的结果,本文也更改了随机森林的参数(决策树个数设定为由500改为300)进行稳健性检验。结果如下。

附表1 不同模型的AUC比较

	随机森林 (决策树数量=300)	随机森林 (决策树数量=500)	GBDT	Adaboost	逻辑回归
传统数据	0.6751	0.6759	0.6288	0.6185	0.595
所有数据	0.7262	0.7286	0.6825	0.6659	0.6361

资料来源:作者计算。

从结果上来看,GBDT、Adaboost以及决策树数量为300的随机森林模型在传统数据和所有数据的情况下均优于逻辑回归模型,验证了正文中结果的稳健性。当然需要说明的是,本文并非要论证逻辑回归在任何一类问题或者任何一个数据集下的表现都输于其他算法,只是想说明随着机器学习的不断发展,很多算法可以帮助我们进一步提高模型的预测能力。